



TRƯỜNG ĐẠI HỌC SÀI GÒN KHOA CÔNG NGHỆ THÔNG TIN

PHÂN TÍCH DỮ LIỆU CHAPTER 13 VÀ MỤC LỤC A

Sinh viên thực hiện: Lương Thanh Tuấn

Giảng viên hướng dẫn : TS.Đỗ Ngọc Tài

TP. HỒ CHÍ MINH, 10/2025



Nội dung chính

1. Giới thiệu tổng quát về dữ liệu



2. Phân tích khám phá



3. Kết luận



1. Giới thiệu tổng quát về dữ liệu

Bitly data from 1.USA

- Tập dữ liệu này có nguồn gốc từ dịch vụ rút gọn URL Bitly. Vào năm 2011, Bitly đã hợp tác với trang web của chính phủ Hoa Kỳ là USA.gov để cung cấp nguồn cấp dữ liệu ẩn danh thu thập từ những người dùng rút gọn các liên kết kết thúc bằng .gov hoặc .mil.
- Dữ liệu mẫu được bảo tồn cho ví dụ của sách là một trong những tệp dữ liệu có sẵn dưới dạng ảnh chụp nhanh hàng giờ (hourly snapshots).



1. Giới thiệu tổng quát về dữ liệu

Bitly data from 1.USA

- Bộ dữ liệu gồm 18 cột và 3560 dòng trong đó toàn bộ cột đều missing values.

Data columns (total 18 columns):				
#	Column	Non-Null Count		Dtype
---	-----	-----		-----
0	a	3440	non-null	object
1	c	2919	non-null	object
2	nk	3440	non-null	float64
3	tz	3440	non-null	object
4	gr	2919	non-null	object
5	g	3440	non-null	object
6	h	3440	non-null	object
7	l	3440	non-null	object
8	al	3094	non-null	object
9	hh	3440	non-null	object
10	r	3440	non-null	object
11	u	3440	non-null	object
12	t	3440	non-null	float64
13	hc	3440	non-null	float64
14	cy	2919	non-null	object
15	ll	2919	non-null	object
16	_heartbeat_	120	non-null	float64
17	kw	93	non-null	object

1. Giới thiệu tổng quát về dữ liệu

Bitly data from 1.USA

Toàn bộ dữ liệu thì America/New_York có tới 1251 giá trị trong múi giờ, tiếp đến là giá trị không xác định (521) America/Chicago (400), America/Los_Angeles (382) và America/Denver (191).

```
clean_tz = frame["tz"].fillna("Missing")
clean_tz[clean_tz == ""] = "Unknown"
tz_counts = clean_tz.value_counts()
tz_counts.head()
```

```
tz
America/New_York    1251
Unknown             521
America/Chicago     400
America/Los_Angeles 382
America/Denver      191
Name: count, dtype: int64
```

Sau khi tách cột a (user-agent) cho thấy rằng có tới 2594 người sử dụng Mozilla/5.0 và Mozilla/4.0 (601) điều này cho thấy Mozilla được ưu chuộng nhất so với các trình duyệt còn lại.

```
results = pd.Series([x.split()[0] for x in frame["a"].dropna()])
results.head(5)
results.value_counts().head(8)
```

```
Mozilla/5.0          2594
Mozilla/4.0          601
GoogleMaps/RochesterNY 121
Opera/9.80            34
TEST_INTERNET_AGENT  24
GoogleProducer        21
Mozilla/6.0           5
BlackBerry8520/5.0.0.681 4
Name: count, dtype: int64
```




1. Giới thiệu tổng quát về dữ liệu

Bitly data from 1.USA

Để dàng nhận thấy số người dùng Windows chiếm toàn bộ cho toàn bộ múi giờ.


```
agg_counts = by_tz_os.size().unstack().fillna(0)
agg_counts.head()
```

os	tz	
	Not Windows	Windows
	245.0	276.0
Africa/Cairo	0.0	3.0
Africa/Casablanca	0.0	1.0
Africa/Ceuta	0.0	2.0
Africa/Johannesburg	0.0	1.0

2. Phân tích khám phá

Bitly data from 1.USA

Dựa vào ảnh này càng trực quan hơn về tần suất người sử dụng hệ điều hành windows cao gấp đôi số người không sài hệ điều hành Windows. Càng chứng minh được người dùng hệ điều hành Windows là đông đảo nhất



1. Giới thiệu tổng quát về dữ liệu

MovieLens

MovieLens 1M Dataset Tập dữ liệu này được cung cấp bởi GroupLens Research. Nó chứa một số bộ sưu tập dữ liệu xếp hạng phim được thu thập từ người dùng của MovieLens vào cuối những năm 1990 và đầu những năm 2000. Cụ thể, tập dữ liệu MovieLens 1M chứa một triệu xếp hạng được thu thập từ sáu nghìn người dùng trên bốn nghìn bộ phim.





1. Giới thiệu tổng quát về dữ liệu

Movielens


Vào năm 1880, 1000 tên phổ biến nhất được xuất hiện tại thời điểm này theo ảnh trên.
Tỷ lệ tên Mary là nhiều nhất

		name sex births year prop					
year	sex						
1880	F	0	Mary	F	7065	1880	0.077643
		1	Anna	F	2604	1880	0.028618
		2	Emma	F	2003	1880	0.022013
		3	Elizabeth	F	1939	1880	0.021309
		4	Minnie	F	1746	1880	0.019188

2. Phân tích khám phá

Movielens


Từ những năm 1880 đến cuối năm 1933 thì số lượng Female chiếm đa số, tuy nhiên có sự biến động và chuyển biến từ năm 1950 đến hiện tại của nghiên cứu thì số lượng Male lại chiếm ưu thế.



2. Phân tích khám phá

Movielens


Đây là 4 cái tên có số lượng đặt nhiều nhất và tùy vào những năm sẽ có sự phân bố giữa các loại tên này.



2. Phân tích khám phá

Movielens

Ngoài ra tỷ lệ top 50% dân số dành cho Female, điều này có thể thấy rằng đa số mọi người sẽ đẻ con là con gái hơn là con trai.





1. Giới thiệu tổng quát về dữ liệu

USDA Food

USDA Food Database Tập dữ liệu này là cơ sở dữ liệu về thông tin dinh dưỡng thực phẩm của US Department of Agriculture (USDA) (Bộ Nông nghiệp Hoa Kỳ). Lập trình viên Ashley Williams đã tạo ra một phiên bản của cơ sở dữ liệu này ở định dạng JSON.



United States
Department of
Agriculture

1. Giới thiệu tổng quát về dữ liệu

USDA Food


Bộ dữ liệu bao gồm 4 cột và 6636 dòng, cột manufacturer là cột duy nhất bị missing values

```
RangeIndex: 6636 entries, 0 to 6635
Data columns (total 4 columns):
#   Column                Non-Null Count  Dtype
---  -
0   description            6636 non-null   object
1   group                  6636 non-null   object
2   id                     6636 non-null   int64
3   manufacturer           5195 non-null   object
```

2. Phân tích khám phá

USDA Food

Chất lượng dinh dưỡng của thịt bò là nhiều nhất, tiếp theo là dê, bò sữa...



3. Kết luận

Dựa trên các phát hiện sau khi đã khám phá, thì chúng ta cần tập trung quan sát các yếu tố ảnh hưởng mạnh đến chất lượng của rượu (Volatile_acidity,

Ảnh hưởng mạnh	Ảnh hưởng nhẹ	Không ảnh hưởng
Volatile axidity [<0.7]	Fixed axidity [12-14]	Chlories
Citric_acid [>0.5]	Total_SO2 [70-120]	Resudal Sugar
Sulphates [0.75-1.20]	Density [< 0.993]	Free SO2
Alcohol [11-14]	pH [2.8-3.0]	

Ngoài ra cũng cần xem xét các yếu tố ít ảnh hưởng, vì chúng cũng có thể là mối nguy cơ ảnh hưởng đến chất lượng của rượu (giả sử như đảm bảo lượng SO2 phù hợp để đảm bảo sức khỏe người dùng, ...)



TRƯỜNG ĐẠI HỌC SÀI GÒN KHOA CÔNG NGHỆ THÔNG TIN

**THANK YOU
FOR LISTENING**